



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

تمرین تئوری مربوط به پروژه اول
درس شبکه ی عصبی

نگارش

تینا حسن نسب عمران (40113008)

نگار یگانه سرهنگی (40113008)

آبان ۱۴۰۴

مفهوم بیش‌پارامتری‌سازی (Overparameterization)

در نظریه‌ی کلاسیک یادگیری ماشین، افزایش ظرفیت مدل (تعداد پارامترها) معمولاً باعث افزایش واریانس و کاهش تعمیم‌پذیری می‌شد. اما در مدل‌های مدرن مانند شبکه‌های عصبی عمیق، پدیده‌ای متفاوت دیده می‌شود: حتی وقتی تعداد پارامترها بسیار بیشتر از نمونه‌های آموزشی است (یعنی مدل بیش‌پارامتری است)، مدل می‌تواند با وجود فیت کامل داده‌ها، همچنان روی داده‌های جدید عملکرد خوبی داشته باشد. این وضعیت زمانی رخ می‌دهد که مدل وارد ناحیه‌ی *Overparameterized* می‌شود و الگوریتم یادگیری می‌تواند از میان بی‌نهایت راه‌حل ممکن، تابعی ساده‌تر و سازگارتر با داده‌ها را انتخاب کند که در ادامه دلیل این انتخاب توضیح داده می‌شود.

به بیان دیگر، برخلاف دیدگاه کلاسیک، ظرفیت زیاد مدل (*model capacity*) لزوماً موجب *overfitting* نمی‌شود.

نقطه‌ی درون‌یابی (Interpolation Point)

نقطه‌ی درون‌یابی، مرزی است که در آن مدل برای اولین بار می‌تواند تمام داده‌های آموزشی را دقیقاً فیت کند؛ یعنی خطای آموزش (*Training Loss*) برابر با صفر می‌شود. در نمودار *Double Descent*، این نقطه رأس منحنی است که بین ناحیه‌ی *Underparameterized* و ناحیه‌ی *Overparameterized* قرار دارد. قبل از این نقطه، افزایش ظرفیت مدل موجب *overfitting* و افزایش خطای تست می‌شود، اما پس از عبور از آن، عملکرد دوباره بهبود می‌یابد.

مفهوم همواری (Smoothness) و دلیل ارجحیت توابع هموار

در مقاله، «همواری» ویژگی‌ای از تابع یادگرفته‌شده نسبت به ورودی‌ها است؛ یعنی تابع خروجی باید به آرامی نسبت به تغییرات کوچک در داده‌های ورودی تغییر کند. چنین توابعی معمولاً «حساسیت کمتر» به داده آموزشی دارند، و بنابراین کمتر احتمال دارد که نویز را یاد بگیرند یا روی بخشی از داده یا ویژگی‌ها که اطلاعات مفید خیلی کمی درباره‌ی برچسب یا هدف یادگیری به مدل می‌دهند و بیشتر شبیه نویز یا تغییرات تصادفی هستند، *overfit* کنند. این خاصیت با یک نرم در فضای تابعی مثل *RKHS norm* اندازه‌گیری می‌شود. تابعی که نرم کوچک‌تر و رفتار نرم‌تری دارد، ساده‌تر است و به نوعی مصداق اصل *Occam's Razor* است که می‌گوید اگر چند مدل یا توضیح بتوانند داده‌ها را توضیح دهند، مدل ساده‌تر

و کم‌پیچیدگی‌تر معمولاً بهتر است. این توابع نوسانات کمتری دارند و در نتیجه تعمیم بهتری روی داده‌های جدید خواهند داشت.

وقتی تابع در فضای ورودی به شدت تغییر کند (تیز باشد)، اطراف داده‌ی آموزشی ممکن است نویز را نیز فیت کرده باشد، و بنابراین مدل عمومی‌سازی ضعیف‌تری خواهد داشت. بنابراین، تابع هموارتر یعنی حساسیت کمتر به جزییات نویزی و حرکت آرام‌تر در اطراف ورودی‌ها و در نتیجه تعمیم بهتر.

نقش همواری در کاهش خطای تعمیم (Double Descent)

در سمت راست نقطه‌ی درونیابی، تمام مدل‌ها داده‌ها را دقیق فیت می‌کنند، اما تنها برخی از آن‌ها (آن‌هایی که «هموارتر» و کم‌نرم‌ترند) تعمیم بهتری دارند. با افزایش ظرفیت مدل، فضای توابع بزرگ‌تر می‌شود و امکان انتخاب تابعی نرم‌تر که داده‌ها را فیت می‌کند بیشتر می‌گردد؛ در نتیجه خطای تست کاهش می‌یابد. این روند همان بخش دوم نزول در منحنی Double Descent است که نشان می‌دهد بیش‌پارامتری‌سازی می‌تواند منجر به بهبود مجدد تعمیم‌پذیری شود.